



Breast Cancer Study



Übung: Random Forest

- Das Ziel dieser Aufgabe ist es, sich mit Ensemble-Lernmethoden vertraut zu machen. Sie arbeiten mit dem **Breast Cancer Wisconsin** Datensatz. Sie starten mit dem Random Forest Ansatz und vergleichen diesen später mit anderen Methoden.
- **Libraries:** pandas, numpy, scikit-learn, xgboost, lightgbm, matplotlib, seaborn
- **Daten:**

```
from sklearn.datasets import load_breast_cancer  
data = load_breast_cancer()
```
- **Beschreibung:** Der Datensatz besteht aus 569 Proben von malignen und benignen Tumorzellen, die jeweils durch 30 Merkmale beschrieben werden, die aus digitalisierten Bildern berechnet wurden.
- **Aufgaben:**
 - Laden Sie die **Daten** für Features und Targetvariable
 - Verschaffen Sie sich einen initialen Überblick über die Daten (**Missing Values**)
 - **Nutzen Sie den StandardScaler() zur Normalisierung** der Features
 - Teilen Sie die Daten in **Trainings-** und **Testdatensatz**
 - **Importieren** Sie den Random Forest Klassifikator und Evaluationsmetriken
 - Trainieren Sie den **Klassifikator**
 - Treffen Sie eine **Vorhersagen**
 - **Bewerten** Sie die Modellgüte

→ Während der Aufgabe wird eine Python Datei mit Hilfestellung auf FELIX gestellt.

Wir haben in der letzten Session gelernt wie man die Feature Importance nutzt um relevante von redundanten Variablen zu trennen. Wenden Sie nun Ihr Wissen an!

- **Aufgaben:**

- Extrahieren Sie die Feature-Importance des Modells
- Wählen Sie die wichtigsten (z.B 10) Features aus
- Erstellen Sie neue Trainings- und Testsets mit den ausgewählten Merkmalen
- Trainieren Sie das Modell erneut
- Bewerten Sie die Modellergebnisse

→ Während der Aufgabe wird eine Python Datei mit Hilfestellung auf FELIX gestellt.

Nach dem Bagging Ansatz schauen wir nun wie wir mit dem Boosting Ansatz abschneiden. Trainieren Sie einen XGBoost Klassifikator und vergleichen Sie dessen Leistung mit dem Random Forest Modell.

- **Aufgaben:**

- Installieren und Importieren Sie den XGBoost Klassifikator
- Trainieren Sie das XGBoost Modell
- Machen Sie eine Vorhersage
- Bewerten Sie die Modellergebnisse

→ Während der Aufgabe wird eine Python Datei mit Hilfestellung auf FELIX gestellt.

Übung: XGBoost mit Grid Search

Verbessern Sie die Leistung des XGBoost Modells, indem Sie dessen Hyperparameter mithilfe von Grid Search optimieren.

- **Aufgaben:**

- Importieren von GridSearchCV
- Legen Sie einen Bereich von Hyperparametern fest, über die gesucht werden soll.
- Finden und zeigen Sie die besten Parameter an
- Trainieren Sie das optimierte XGBoost Modell
- Bewerten Sie die Modellergebnisse

→ Während der Aufgabe wird eine Python Datei mit Hilfestellung auf FELIX gestellt.

Übung: LightGBM

Bitte führen Sie die Klassifikation noch einmal mit LightGBM durch und vergleichen anschließend die Ergebnisse.